Examen domiciliario de R

Informe

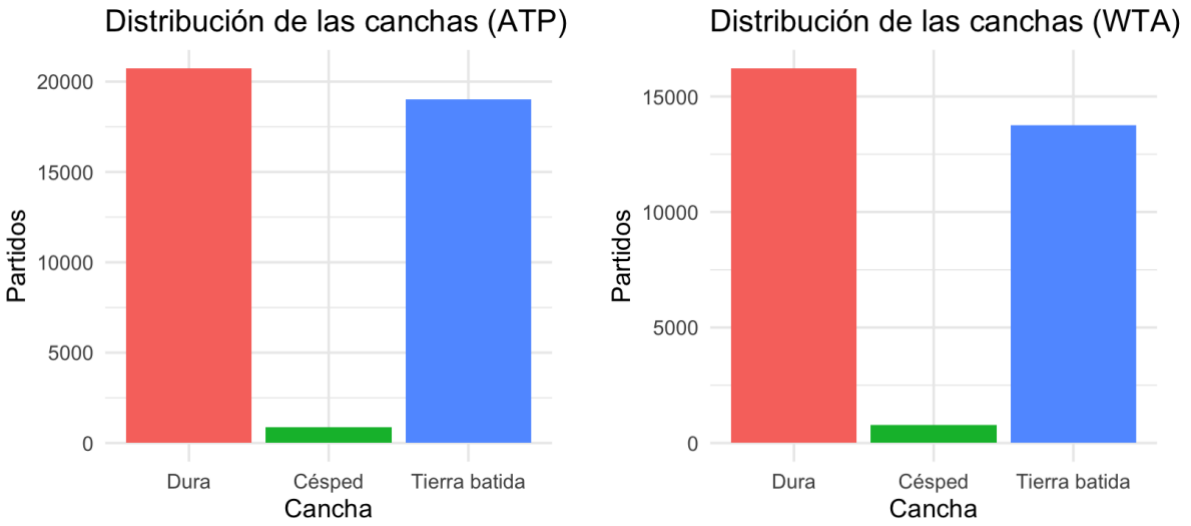
1. Análisis de Datos Deportivos: Circuito de Tenis (ATP / WTA)

Pregunta 1 : ¿Entre los jugadores ATP que han disputado al menos 25 partidos esta temporada, quiénes son los 10 mejores en cuanto a porcentaje de victorias?

Los 10 mejores (de mejor a peor) son respectivamente :

1. Jannik Sinner
2. Carlos Alcaraz
3. Dragos Nicolae Madaras
4. Soon-Woo Kwon
5. Max Basing
6. Toby Samuel
7. Raphael Perot
8. Novak Djokovic
9. Tuncay Duran
10. Felix Gill

Pregunta 2 : ¿Cuál es la distribución de los partidos disputados por tipo de superficie (pista dura, tierra batida, césped) según el circuito (ATP vs WTA)?



El circuito ATP tiene más partidos pero la distribución de partidos por superficie es prácticamente identical entre la ATP y la WTA. La pista dura es la superficie predominante, seguida muy de cerca por la tierra batida. En cambio, el césped

representa una proporción mínima de partidos en ambos circuitos, lo cual refleja la corta duración de esta temporada en el calendario profesional.

Pregunta 3 : ¿Cuáles son los porcentajes de victorias en cada tipo de superficie de Grand Slam de los ganadores de cada Grand Slam?

Los jugadores que hayan ganado uno o más títulos de Grand Slam durante la temporada 2025 son: Jannik Sinner, Carlos Alcaraz, Madyson Keys, Aryna Sabalenka, Iga Swiatek y Cori Gauff

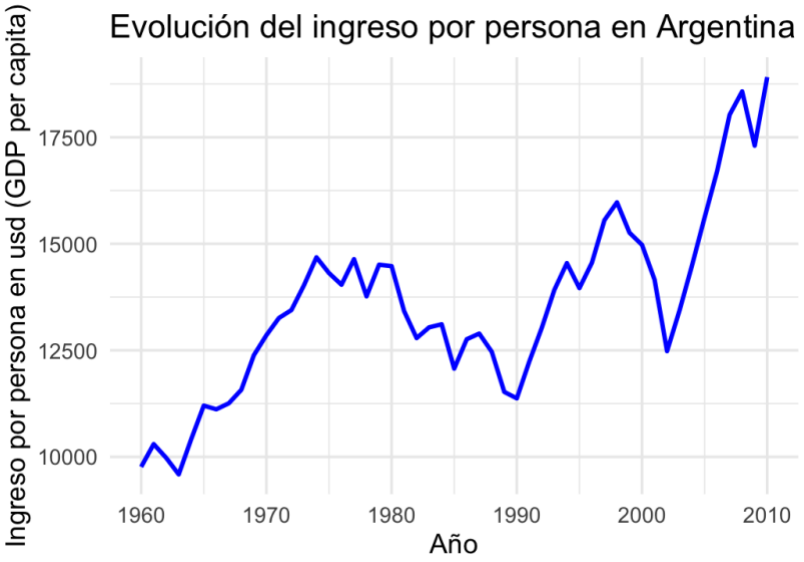
La columna "tournament" indica si el jugador ha ganado un Grand Slam en la superficie (columna “surface”) analizada.

	gender	player_id	player_name	surface	partidos	victorias	tasa_victoria	tournament
1	atp	22691	Jannik Sinner	dur	27	24	0.8888889	Australian Open – Melbourne
2	atp	22691	Jannik Sinner	gazon	9	8	0.8888889	Wimbledon – London
3	atp	22691	Jannik Sinner	terre battue	13	11	0.8461538	*NA*
4	atp	22877	Carlos Alcaraz	dur	32	28	0.8750000	U.S. Open – New York
5	atp	22877	Carlos Alcaraz	gazon	12	11	0.9166667	*NA*
6	atp	22877	Carlos Alcaraz	terre battue	23	22	0.9565217	French Open – Paris
7	wta	748	Madison Keys	dur	29	23	0.7931034	Australian Open – Melbourne
8	wta	748	Madison Keys	gazon	7	4	0.5714286	*NA*
9	wta	748	Madison Keys	terre battue	13	9	0.6923077	*NA*
10	wta	13568	Aryna Sabalenka	dur	40	34	0.8500000	U.S. Open – New York
11	wta	13568	Aryna Sabalenka	gazon	9	7	0.7777778	*NA*
12	wta	13568	Aryna Sabalenka	terre battue	21	18	0.8571429	*NA*
13	wta	18209	Iga Swiatek	dur	50	40	0.8000000	*NA*
14	wta	18209	Iga Swiatek	gazon	11	10	0.9090909	Wimbledon – London
15	wta	18209	Iga Swiatek	terre battue	15	11	0.7333333	*NA*
16	wta	21328	Cori Gauff	dur	37	28	0.7567568	*NA*
17	wta	21328	Cori Gauff	gazon	2	0	0.0000000	*NA*
18	wta	21328	Cori Gauff	terre battue	21	18	0.8571429	French Open – Paris

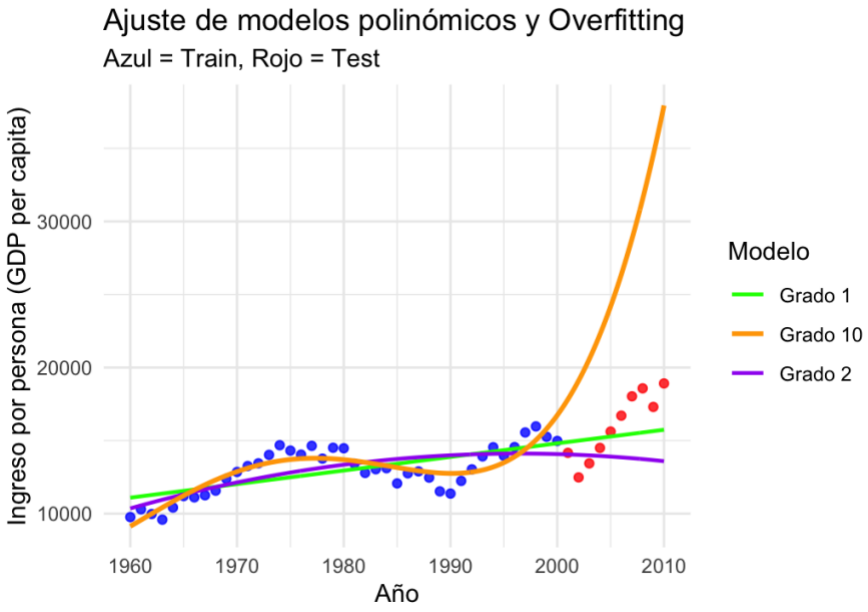
Los resultados confirman que cada uno de los ganadores de Grand Slam registró, efectivamente, su porcentaje de victorias más alto en la superficie en la que conquistó su respectivo título. Tanto en la ATP como en la WTA, el éxito en estos torneos está directamente vinculado al dominio especializado de cada superficie, destacando rendimientos sobresalientes como el de Carlos Alcaraz en tierra batida (95.6%) o el de Iga Swiatek en césped (90.9%), lo que demuestra la capacidad decisiva de estos jugadores para maximizar su efectividad en sus canchas principales.

2. Ejercicio: Análisis econométrico con datos de gapminder

Parte 1: Ingreso por persona



En Argentina, el ingreso por persona muestra una tendencia general creciente entre 1960 y 2010, pasando de 9'589 a 18'912 usd. La evolución no es lineal, vemos una cierta volatilidad, hay un crecimiento mas o menos constante hasta finales de los años 70 pero se degrada en los 80. Finalmente, despues de 2000 y hasta 2010 se observa un rápido aumento que lleva la variable a su punto más alto del período.




```
RMSE en TRAIN:                          RMSE en TEST:
   Lineal      Quad      Deg10      Lineal      Quad      Deg10
1212.7475 1159.9654  730.6231   2012.472  3114.474 11311.216
```

Al comparar los tres modelos, se observa un claro problema de overfitting en el modelo de Grado 10. Aunque obtiene el error más bajo en el conjunto de entrenamiento (RMSE de 730.6 frente a 1212.7 en el lineal), su error en el conjunto de testeo se dispara astronómicamente hasta 11,311.2, mostrando una pésima capacidad de generalización fuera de los datos de entrenamiento. En cambio, los modelos de Grado

1 (lineal) y Grado 2 (cuadrático) mantienen un rendimiento mucho más estable y realista en test (RMSE de 2012.5 y 3114.5 respectivamente), demostrando que una mayor complejidad polinómica no garantiza mejores predicciones.

Matriz de correlaciones

	Argentina	Bolivia	Chile	Ecuador
Argentina	1.0000000	0.9244884	0.7650413	0.7895280
Bolivia	0.9244884	1.0000000	0.7450691	0.8525295
Chile	0.7650413	0.7450691	1.0000000	0.7148094
Ecuador	0.7895280	0.8525295	0.7148094	1.0000000

Matriz de correlaciones entre las variaciones porcentuales anuales

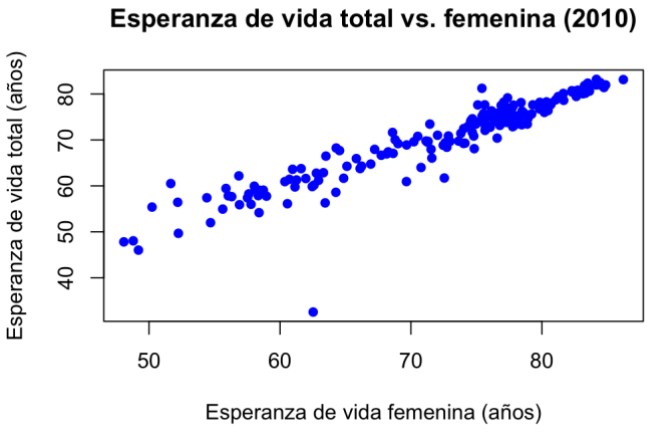
	Argentina	Bolivia	Chile	Ecuador
Argentina	1.0000000	0.2080898	0.170010588	0.217027990
Bolivia	0.2080898	1.0000000	0.150289406	0.432667600
Chile	0.1700106	0.1502894	1.000000000	-0.008756581
Ecuador	0.2170280	0.4326676	-0.008756581	1.000000000

Se observa una correlación positiva muy alta entre los niveles de ingreso de todos los países (valores entre 0.71 y 0.92). Esto se debe a que la mayoría de estas economías han experimentado una tendencia creciente de largo plazo sostenida en el tiempo.

Al analizar las variaciones porcentuales (ΔY/Y), las correlaciones disminuyen drásticamente. Muestran valores bajos (en general menores a 0.22) e incluso ligeramente negativos (como entre Chile y Ecuador: -0.008).

Mientras que la tendencia a largo plazo es similar para la región, los shocks de corto plazo y los ciclos económicos son independientes y específicos de la política interna de cada país.

Parte 2: Esperanza de vida y género



Se observa una relación lineal positiva extremadamente fuerte entre ambas variables. A medida que aumenta la esperanza de vida de las mujeres, la esperanza de vida total aumenta casi en la misma proporción.

El coeficiente estimado para 'life_expectancy_female' es cercano a 0.90. El R^2 es de ~ 0.87, lo que indica que la esperanza de vida femenina explica aproximadamente el 87% de la variabilidad de la esperanza de vida total. Este resultado es esperado ya que la esperanza de vida total es una media ponderada entre hombres y mujeres.

El p-valor es extremadamente pequeño y $p < 0.05$, por lo que rechazamos la hipótesis nula H0. Existe evidencia empírica suficiente para afirmar que la esperanza de vida femenina es estadísticamente mayor a la esperanza de vida promedio general.

Con el nivel de ingreso, el coeficiente de 'life_expectancy_female' disminuye levemente (pasa de 0.90 a 0.80) pero sigue siendo altamente significativo. El ingreso por persona tiene un efecto positivo y significativo sobre la esperanza de vida. La ganancia en R^2 es marginal (pasa de ~ 0.874 a ~ 0.880) debido a la altísima multicolinealidad estructural entre la esperanza de vida femenina y la total.

¿Vale la pena incluir la variable income per person?

No vale la pena desde un punto de vista estadístico y práctico. Aunque el coeficiente del ingreso por persona resulta estadísticamente significativo, la ganancia en la capacidad explicativa del modelo es marginal: el R^2 aumenta solo de 0.874 a 0.880.

Esta falta de aporte relevante se debe a la fuerte multicolinealidad entre la esperanza de vida femenina y la esperanza de vida total. La variable life_expectancy_female ya captura casi la totalidad de la varianza (alrededor del 87%), por lo que incluir el ingreso por persona apenas aporta información nueva y añade complejidad innecesaria al modelo.

Modelo lineal con 3 covariables (excluyendo life_expectancy_female)

Excluyo tambien "life_expectancy_male" para evitar redundancia tautométrica, selecciono variables socioeconómicas y demográficas:

1. **log(income_per_person):** representa el nivel de desarrollo económico.
2. **child_mortality:** refleja las condiciones del sistema de salud e infraestructura sanitaria.
3. **children_per_woman:** indicador demográfico.

Este modelo tiene tambien un R^2 elevado (~ 0.81), explicando más del 81% de la varianza de la esperanza de vida sin recurrir a datos directos de género. La mortalidad infantil tiene un impacto negativo y altamente significativo sobre la esperanza de vida general.